

Temas Selectos de Física Computacional III:
Introducción a la Ciencia de Datos.
Clase 2: 02 de septiembre de 2026

Dr. Jaime Octavio Guerra Pulido

1 Conjunto de datos Global Land Temperature

El conjunto de datos de Temperatura Global de la Tierra (Global Land Temperature, GLT) es una gran colección de mediciones mantenidas activamente por Berkeley Earth (<https://berkeleyearth.org/data/>). Contiene los datos fuente en bruto medidos con estaciones alrededor del mundo, además de un formato intermedio y varios archivos de salida formateados. Los datos abarcan desde aproximadamente 1750 hasta días recientes con disponibilidad mensual y diaria. Las mediciones se proporcionan por hemisferios, estados, países, ciudades y más.

Trabajarás con una versión modificada, más pequeña pero más difícil, del conjunto de datos original de GLT, para destacar la importancia del preprocesamiento de datos. Más específicamente, esta versión didáctica contiene los archivos de salida formateados de las principales ciudades del mundo con granularidad mensual. Por simplicidad, el análisis abarcará casi dos siglos (es decir, entre los años 1817 y 2012).

El conjunto de datos está compuesto por aproximadamente 200,000 filas correspondientes a las mediciones tomadas el primer día del mes en una ciudad dada. Cada medición se describe con 7 valores:

- Fecha en la que se tomó la medición,
- temperatura media (*AverageTemperature*),
- incertidumbre de la temperatura media (*AverageTemperatureUncertainty*),
- Ciudad desde donde se tomó la medición,
- país,
- latitud,
- longitud

El conjunto de datos está disponible en formato CSV:

GLT_filtrado.csv

Empecemos¹:

1. Carga el conjunto de datos de Temperatura Global de la Tierra como una lista de listas. Vamos a practicar ahora usando Pandas:

```
import pandas as pd
df = pd.read_csv('/content/GLT_filtrado.csv', encoding='utf-8')
```

2. Tómate un momento para inspeccionar mejor los atributos con los que vas a trabajar. Cuántos de ellos son continuos o discretos, valores o texto? Cuántas entradas hay? Cuántas ciudades distintas?
3. Convierte la columna `Date` de texto a una fecha (`datetime`) para poder trabajar con años, meses, ordenar por tiempo, etc., y crea una nueva columna `Year` extrayendo el año de cada fecha.

```
df['Date'] = pd.to_datetime(df['Date'])
df['Year'] = df['Date'].dt.year
```

4. Filtra una ciudad (por ejemplo, México):

```
ciudad = 'Mexico'
d = df[df['City'] == ciudad]
print("Filas:", len(d))
```

5. Calcula la temperatura media anual:

```
media_anual = d.groupby('Year')['AverageTemperature'].mean()
print(media_anual.head())
```

6. Grafica el resultado:

```
import matplotlib.pyplot as plt
plt.figure()
plt.plot(media_anual.index, media_anual.values, marker='o')
plt.title(f'Temperatura media anual en Mexico')
plt.xlabel('Año')
plt.ylabel('Temperatura')
plt.show()
```

¹En este momento, puedes usar la herramienta que prefieras, como Python puro, NumPy, Pandas u otras bibliotecas para manejar y analizar los datos.

```
media_anual = d.groupby('Year')['AverageTemperature'].mean().dropna()
X = media_anual.index.values.reshape(-1, 1)
y = media_anual.values
X_norm = (X - X.min()) / (X.max() - X.min())
```

7. ¿Podrías leer el archivo usando numpy? ¿Podrías replicar los resultados anteriores usando sólo numpy? ¿Qué herramienta crees que te permite hacer más eficientemente el proceso? ¿Por qué?