

Temas Selectos de Física Computacional III:
Introducción a la Ciencia de Datos.
Clase 3: 04 de septiembre de 2026

Dr. Jaime Octavio Guerra Pulido

1 Introducción

En esta clase, se van a inspeccionar dos conjuntos de datos, estudiar los valores atípicos (outliers), aplicar un método estándar para reducir su influencia (IQR capping) y, después, detectar valores faltantes y hablar de como rellenarlos en el caso de datos temporales.

2 Inspección de un conjunto desconocido

Comienza con un conjunto de datos desconocido:

```
data = pd.read_csv('dataset.csv')
```

Cosas que debes revisar:

- Tamaño del dataset:

```
data.shape
```

- Vista rápida de las primeras filas:

```
data.head()
```

- Información general del dataset (tipos de columnas, memoria, etc.):

```
data.info()
```

- Cuántos valores faltantes tiene cada columna:

```
data.isnull().sum()
```

- Estadística descriptiva:

```
data.describe()
```

Ahora responde: en cuales variables puedes ver mínimos o máximos que no tienen sentido y una desviación estándar enorme?

Eso suele ser una señal de outliers o errores de captura.

3 Visualización: boxplot y violin plot

Vamos a encontrar outliers usando Matplotlib y Seaborn.

Un **boxplot** muestra dónde cae el 50% central de los datos (la caja), la mediana (la línea), y hasta dónde llegan los valores no-atípicos (los “bigotes”). La parte inferior de la caja es Q1 (percentil 25) y la superior es Q3 (percentil 75).

```
import seaborn as sns
import matplotlib.pyplot as plt
plt.figure(figsize=(10, 2))
plt.subplot(1, 2, 1)
sns.boxplot(x=data['var1'])
plt.subplot(1, 2, 2)
sns.boxplot(x=data['var2'])
plt.tight_layout()
plt.show()
```

Un **violin plot** representa la distribución con *kernel density estimation* (KDE). Zonas más anchas significan mayor densidad de probabilidad; zonas angostas indican pocos datos. También suele marcar la mediana. La forma completa ayuda a ver el sesgo (skewness) y valores extremos.

```
plt.figure(figsize=(10, 2))
plt.subplot(1, 2, 1)
sns.violinplot(x=data['var1'], color="blue")
plt.subplot(1, 2, 2)
sns.violinplot(x=data['var2'], color="blue")
plt.tight_layout()
plt.show()
```

4 ¿Qué hacer con los outliers?

- Eliminar outliers por completo (si son errores reales).
- Dejarlos tal cual (si son legítimos y tu modelo es robusto).
- Aplicar IQR capping (si quieres reducir la influencia de extremos, sin borrar filas).

El método **Interquartile Range (IQR) capping** limita los valores al intervalo:

$$(Q1 - 1.5 \cdot IQR) \leq x \leq (Q3 + 1.5 \cdot IQR), \quad IQR = Q3 - Q1$$

Cualquier valor por debajo del límite inferior o por encima del superior se “recorta” (se *cappea*), reduciendo la influencia de outliers extremos.

```
data_no_outliers = data.copy()

for col in data_no_outliers.select_dtypes(include=[np.number]).columns:
    Q1 = data_no_outliers[col].quantile(0.25)    # Primer quartile (25%)
    Q3 = data_no_outliers[col].quantile(0.75)    # Tercer quartile (75%)
    IQR = Q3 - Q1                                # Rango interquartile

    # limites IQR
    lower_bound = Q1 - 1.5 * IQR
    upper_bound = Q3 + 1.5 * IQR

    # contador
    outliers_count = (
        (data_no_outliers[col] < lower_bound)
        | (data_no_outliers[col] > upper_bound)
    ).sum()

    # apping
    data_no_outliers[col] = np.clip(data_no_outliers[col], lower_bound, upper_bound)

    print(f"'{col}': {outliers_count} outliers capped
    | Bounds: [{lower_bound:.2f}, {upper_bound:.2f}]")

print("\nOutlier capping completed.")
```

5 Valores faltantes en Global Land Temperature

El conjunto de datos GLT es el mismo que el de la clase pasada y está disponible en formato CSV:

GLT_filtrado.csv

Analiza el atributo *AverageTemperature*, que contiene valores faltantes. Cuenta cuantos valores faltantes tienes en el conjunto. Puedes usar:

```
df['AverageTemperature'].isna().sum()
```

¿Crees que es un porcentaje grande del total de datos?

Existen muchas formas de manejar valores faltantes. Se puede decidir **eliminar** una fila del conjunto de datos si contiene un valor faltante. Esta estrategia puede adoptarse cuando el conjunto de datos es grande y la pérdida de información no afecta la distribución general.

Otra solución común es **llenar cada valor faltante**. Si los datos no tienen un orden específico, se pueden reemplazar con la media (o la mediana) del atributo involucrado.

Los datos temporales, en cambio, permiten **reemplazar** los valores faltantes con los valores de las **filas adyacentes**, por ejemplo, promediándolos. Claramente, esta técnica es posible si el tipo de datos permite calcular la media.

A continuación, se presenta un método para rellenar las filas faltantes: *llena cualquier vacío con la media aritmética entre la medición antecedente más cercana y la medición sucesiva más cercana en el tiempo*, tomadas en la misma ciudad. Asume las siguientes reglas para casos extremos:

1. Puede suceder que un valor faltante no tenga una medición precedente (o sucesiva). Esto sucede cuando el valor faltante es el primer (o el último) valor del conjunto de datos. Si este es el caso, considera que el valor faltante está precedido (o seguido) por un 0; luego calcula la media en consecuencia.

```
original = [ '', 5, 6, '' ]  
paso_1 = [ 2.5, 5, 6, '' ] # (0 + 5) / 2  
paso_2 = [ 2.5, 5, 6, 3 ] # (6 + 0) / 2
```

2. Si hay valores faltantes consecutivos, se calculan en orden temporal y se utilizan los valores recién insertados para evaluar los siguientes. Aquí tienes un ejemplo con una lista simple donde se han aplicado ambas reglas:

```
original = [ '', '', 24, 28.9 ]  
paso_1 = [ 12, '', 24, 28.9 ] # (0 + 24) / 2  
paso_2 = [ 12, 18, 24, 28.9 ] # (12 + 24) / 2
```

Aquí te doy un código que lo hace, pero puedes crear el tuyo:

```
llenar_faltantes.ipynb
```

6 Tarea

Después de aplicar el código y rellenar los valores faltantes de nuestro conjunto de datos, resuelve:

1. Hay una anomalía en la distribución de datos. Con ayuda de Matplotlib y el método IQR, detecta la anomalía. Para ello, realiza los siguientes pasos: 1) Haz una gráfica de la distribución global de **AverageTemperature** usando un histograma. Observas una cola anormal o valores extremadamente grandes? 2) Calcula los límites usando el método IQR y identifica todos los valores fuera de esos límites. Determina qué ciudad X genera la mayoría de esos outliers.
2. Como puedes ver, la ciudad X tiene distribuciones de temperatura muy diferentes. Sin embargo, lo que resulta extraño es la gran diferencia en la magnitud de sus temperaturas. Es posible que todos los sensores de las estaciones estuvieran defectuosos? Qué crees que pudo haber sucedido aquí? Usa tu creatividad para analizarlo y proponer una explicación.
3. Calcula la temperatura media anual para las siguientes ciudades: Roma, New York, Bangkok, Tokyo, Paris, Lima, Cairo, Moscow, Peking, Mexico. Observas algún incremento a lo largo de todo el tiempo de medición? Defiende tu respuesta con gráficas. Y si ahora divides los datos en periodos de 5, 10, 25 años y observas cómo han cambiado las temperaturas medias en esos periodos? En cual de estas ciudades el cambio climático ha sido más pronunciado desde el siglo XIX?