

Temas Selectos de Física Computacional III:

Introducción a la Ciencia de Datos.

Clase 4: 11 de septiembre de 2026

Dr. Jaime Octavio Guerra Pulido

1 Introducción

En esta clase, se realizará el cálculo de estadísticas descriptivas básicas para varios conjuntos de datos usando **numpy** y **pandas**. También, se verá qué es el coeficiente de correlación de Pearson y de Spearman. Además, los ejemplos ilustran significativamente por qué siempre se deben graficar los datos.

2 Un primer ejercicio

Lo primero que se debe hacer es definir los módulos de **Python** 3 que se usarán:

```
import matplotlib.pyplot as plt
import numpy as np
```

A continuación, se definen dos arreglos **numpy** de puntos:

```
x = np.array([10, 8, 13, 9, 11, 14, 6, 4, 12, 7, 5])
y1 = np.array([8.04, 6.95, 7.58, 8.81, 8.33, 9.96, 7.24, 4.26, 10.84, 4.82, 5.68])
```

Ahora, dibuja los puntos $(x_i, y1_i)$ formados por los elementos de los arreglos **x** y **y1**. El código es:

```
plt.figure()
plt.scatter(x, y1)
plt.xlim(0, 20)
plt.ylim(2, 14)
plt.xlabel("X")
plt.ylabel("Y")
plt.show()
```

Calcule la media mediante:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i,$$

mediante el comando `np.mean(x)`.

También calcule la varianza:

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

con el código `np.var(x)`.

Imprima los valores con un sólo dígito de precisión después del punto decimal:

```
print(f"Media X: {mean_x:.1f}")
print(f"Varianza X: {var_x:.1f}")
print(f"Media Y: {mean_y:.1f}")
print(f"Varianza Y: {var_y:.1f}")
```

3 Correlaciones de Pearson y Spearman

La correlación utilizada por defecto en el método `df.corr()` de pandas o `np.corrcoef(x, y)` es la correlación lineal de Pearson. Este coeficiente de correlación mide la relación lineal entre dos variables. El coeficiente de correlación de Pearson, r , tiene los siguientes valores:

- $r = 1$: Correlación lineal positiva perfecta.
- $r = 0$: No hay correlación lineal entre las variables.
- $r = -1$: Correlación lineal negativa perfecta.

La fórmula para calcular el coeficiente de correlación de Pearson entre dos variables X e Y es:

$$r_{xy} = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum (X_i - \bar{X})^2 \sum (Y_i - \bar{Y})^2}} \quad (1)$$

Ahora en caso de llamar el método `df.corr(method="spearman")`, se obtiene la correlación de rangos de Spearman. Este coeficiente mide la relación monótona entre dos variables, sin asumir que la relación sea estrictamente lineal. El coeficiente de correlación de Spearman, ρ , tiene los siguientes valores:

- $\rho = 1$: Relación monótona creciente perfecta.
- $\rho = 0$: No hay relación monótona entre las variables.
- $\rho = -1$: Relación monótona decreciente perfecta.

La fórmula para calcular el coeficiente de correlación de Spearman entre dos variables X e Y es:

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)} \quad (2)$$

donde:

- d_i es la diferencia entre los rangos de cada par de valores X_i e Y_i .
- n es el número total de observaciones.

A diferencia de la correlación de Pearson, la correlación de Spearman es útil cuando la relación entre las variables es no lineal pero sigue una tendencia creciente o decreciente.




Figure 1: Comparación de valores de correlación.

Vamos a intentar hacer algunas de estas graficas nosotros:

```
x = np.linspace(-5, 5, 200)
```

```
datasets = {
    "Lineal": 2*x + 1,
```

```

    "Cuadratica": x**2,
    "Seno": np.sin(x),
}

for name, y in datasets.items():
    df = pd.DataFrame({"x": x, "y": y})
    pearson = df.corr().loc["x", "y"]
    spearman = df.corr(method="spearman").loc["x", "y"]

    plt.figure()
    plt.scatter(df["x"], df["y"], s=10)
    plt.title(f"P={pearson:.2f}, S={spearman:.2f}")
    plt.show()

```

Ahora si vamos a calcular la correlación de Pearson de nuestra lista, crea un dataframe primero de esa lista y aplica corr():

```

df = pd.DataFrame({
    "x": x,
    "y1": y1
})

pearson = df.corr().loc["x", "y1"]
print(round(pearson, 2))

```

4 Datos del cuarteto de Anscombe

Ahora vamos a hacer lo mismo, que es graficar, calcular la media y la varianza, y la correlación de Pearson para estas 3 nuevas listas:

```

y2 = [9.14, 8.14, 8.74, 8.77, 9.26, 8.10, 6.13, 3.10, 9.13, 7.26, 4.74]
y3 = [7.46, 6.77, 12.74, 7.11, 7.81, 8.84, 6.08, 5.39, 8.15, 6.42, 5.73]

x4 = [8, 8, 8, 8, 8, 8, 8, 8, 19, 8, 8]
y4 = [6.58, 5.76, 7.71, 8.84, 8.47, 7.04, 5.25, 12.50, 5.56, 7.91, 6.89]

```

Evalúa y saca tus conclusiones.

Esto es el "cuarteto de Anscombe" - un conjunto de cuatro conjuntos de datos creados por el estadístico Francis Anscombe en 1973. Estos conjuntos demuestran que **resúmenes estadísticos iguales NO implican distribuciones iguales**.

5 Datasaurus

Se han guardado otras listas de datos en el archivo "datasaurus.csv". Explore el archivo tal como se ha ido haciendo a lo largo del curso.

```
df = pd.read_csv("datasaurus.csv")
```

Vamos a filtrar solo los conjuntos llamados "dino" y "star" de este:

```
df_dino = df[df["dataset"] == "dino"]
df_star = df[df["dataset"] == "star"]
```

```
plt.figure()
plt.scatter(df_dino["x"], df_dino["y"])
plt.show()
```

```
plt.figure()
plt.scatter(df_star["x"], df_star["y"])
plt.show()
```

¿Se ven muy diferentes? Calcule sus medias, varianzas y su correlación de Pearson.

```
mean_dino = df_dino[["x", "y"]].mean()
var_dino = df_dino[["x", "y"]].var()
corr_dino = df_dino[["x", "y"]].corr().loc["x", "y"]
```

Repita para todas las listas contenidas en el archivo.

La regla es: **siempre hay que graficar los datos**. Solo mirar la media o la correlación (usando, por ejemplo: `df.describe()`) puede llevar a conclusiones incorrectas.