

Temas Selectos de Física Computacional III:

Introducción a la ciencia de datos

Clase 5: 18 de septiembre de 2026

Dr. Jaime Octavio Guerra Pulido

1 Introducción

En esta clase, se estudiará el conjunto de datos llamado “*Wisconsin Diagnostic Breast Cancer*” (WDBC) usando `pandas` y se aplicarán los coeficientes de correlación de Pearson y de Spearman para encontrar correlaciones entre las diferentes variables del conjunto de datos. Además, se usará por primera vez `scikit-learn` y se revisarán las primeras bases para la clasificación.

2 Conjunto de datos de cáncer de mama

El conjunto de datos de cáncer de mama, accesible desde Breast Cancer, se utiliza para predecir si un tumor es benigno o maligno, basándose en 30 características numéricas obtenidas de imágenes digitalizadas de células sanas o tumorales. Estas características describen propiedades físicas como el radio, la textura, el perímetro, el área, la suavidad de los núcleos celulares, entre otros.

El conjunto de datos incluye un total de 569 muestras y está clasificado en dos clases:

- **Maligno:** Tumor canceroso (clase 0).
- **Benigno:** Tumor no canceroso (clase 1).

El conjunto incluye 30 características calculadas para cada imagen de una masa mamaria, derivadas de imágenes digitalizadas de aspiraciones con aguja fina del tejido mamario. Estas características describen propiedades de los núcleos celulares en la imagen.

- **Características medias (3-12):** Representan el valor promedio de cada característica para todos los núcleos celulares en la imagen.
- **Error estándar (13-22):** Representa el error estándar de la característica medida, proporcionando una estimación de la variación.

- **Peores características (23-32):** Se calculan como la media de los tres valores más grandes de cada característica en una imagen.

Entre las principales características numéricas presentes en el conjunto de datos se encuentran:

- **radio:** Distancia desde el centro hasta los puntos del perímetro.
- **textura:** Desviación estándar de los valores de escala de gris.
- **perímetro:** Medida del perímetro de las células.
- **área:** Área de las células.
- **suavidad:** Variación local en la longitud de los radios.

A continuación, se estudiará el conjunto de datos usando `pandas`:

```
import pandas as pd
# Cargar sin encabezados
df = pd.read_csv('/content/wdbc.data', header=None)
print(df.head())
print(df.shape)
```

Obtenga un resumen estadístico de los datos usando:

```
print(df.describe())
print(df.info())
```

Para saber cuántos casos son benignos (B) y malignos (M), basta con contar la cantidad de veces que aparece cada valor en la segunda columna (*Diagnosis*):

```
print(df.columns)
print(df[1].value_counts())
```

Debido a que los datos no tienen cabecera, entonces, es recomendable crear un diccionario donde se asignen nombres solo a las primeras 6 columnas.

```
nombres_columnas = {
    0: "ID",
    1: "diagnostico",
    2: "radio medio",
    3: "textura media",
    4: "perimetro medio",
    5: "area media"
}
df.rename(columns=nombres_columnas, inplace=True)
print(df.columns)
```

3 Exploración visual de datos

¿Qué pasa si se está interesado en cómo difiere la forma de una distribución entre las dos clases? Podemos simplemente agregar la columna `target` al DataFrame y convertir la columna 'diagnostico' en binaria (M = maligno, B = benigno):

```
df['target'] = df['diagnostico'].map({'M': 0, 'B': 1})
```

Ahora es posible eliminar las columnas no necesarias (por ejemplo, 'ID' y 'diagnostico')?

```
df = df.drop(columns=['ID', 'diagnostico'])
print(df.iloc[:10, :4])
```

Vamos a dibujar los histogramas de las primeras 4 columnas:

```
import matplotlib.pyplot as plt
df.iloc[:, :4].hist(figsize=(12, 8), bins=20)
plt.show()
```

Grafique el conjunto de datos de cáncer de mama utilizando las características *radio medio* y *suavidad media*, coloreando los puntos en función de si el tumor es benigno o maligno.

```
plt.scatter(df['radio medio'], df['textura media'], c=df['target'], cmap='bwr')
plt.xlabel('Radio medio')
plt.ylabel('Textura media')
plt.show()
```

Luego, use la función “*groupby*” y grafique una estimación de densidad de kernel (kde):

```
df.groupby("target")["radio medio"].plot(kind='kde', figsize=(10, 10))
plt.legend(['Maligno', 'Benigno'], loc='upper right')
plt.xlabel('Radio medio')
plt.show()
```

También, se podría generar un histograma que compara la distribución del radio medio entre tumores malignos y benignos en el conjunto de datos.

```
maligno = df[df['target'] == 0] # Clase 'Maligno'
benigno = df[df['target'] == 1] # Clase 'Benigno'

plt.figure(figsize=(10, 10))
plt.hist(maligno['radio medio'], alpha=0.5, label='M', color='red', bins=30)
plt.hist(benigno['radio medio'], alpha=0.5, label='B', color='green', bins=30)
```

```
plt.xlabel('Radio medio')
plt.ylabel('Frecuencia')
plt.legend(loc='upper right')
plt.show()
```

Podemos analizar la matriz completa de dispersión para las primeras 4 características. Aquí cada celda en la matriz de dispersión representa un gráfico de dispersión (*scatter plot*) entre dos variables (una en el eje X y otra en el eje Y). La diagonal muestra histogramas (o gráficos de densidad) de cada variable individual. Las unidades de los ejes de cada gráfico son simplemente los valores de las características seleccionadas.

```
from pandas.plotting import scatter_matrix
scatter_matrix(df.iloc[:, :4], c=df['target'], cmap='bwr')
plt.show()
```

Ahora usaremos “*seaborn*”: visualización estadística de datos para obtener las correlaciones lineales entre las características de entrada.

```
import seaborn as sns
plt.figure(figsize=(10, 10))
sns.heatmap(df.iloc[:, 0:4].corr(), annot=True, square=True, cmap='coolwarm')
plt.show()
```

Ahora analice la matriz de correlación de Pearson y Spearman para **todas las columnas** y elabore sus conclusiones:

1. Reducción de dimensionalidad: Si tuviera que eliminar una de las variables entre radio, perímetro y área, ¿cuál elegiría? ¿Por qué?
2. Relación con el diagnóstico: Si quisiera construir un modelo de clasificación basado sólo en dos variables, ¿cuáles escogería? ¿Por qué?
3. Variables con baja correlación: ¿Si una variable tiene una correlación baja con el objetivo, eso significa que es irrelevante para el modelo de clasificación?
4. Comparación con Pearson: ¿en qué casos podríamos encontrar diferencias significativas entre la correlación de Pearson y la de Spearman?

4 Primeros pasos hacia la clasificación usando Scikit-learn

Scikit-learn (<https://scikit-learn.org/stable/>) es una biblioteca de Python de código abierto que incluye una amplia gama de modelos de machine learning (ML), preprocesamiento, validación y algoritmos de visualización. Dada

su simplicidad, es una muy buena opción tanto para principiantes como para científicos de datos expertos para construir e implementar modelos de ML.

En **Scikit-learn**, un conjunto de datos generalmente tiene dos componentes principales:

Entradas: “Features” o “inputs”: son las variables de nuestros datos, y pueden ser representados mediante una matriz.

Respuesta: “Target” o “output”: es la variable de salida que depende de las variables de características. Generalmente, tenemos una única columna de variable de salida y se representa mediante un vector de respuesta.

5 Conjunto de datos de cáncer desde Scikit-learn

El conjunto de datos de cáncer de mama es accesible desde **Scikit-learn** directamente:

```
import pandas as pd
from sklearn.datasets import load_breast_cancer
cancer = load_breast_cancer()
df = pd.DataFrame(data=cancer.data, columns=cancer.feature_names)
df['target'] = cancer.target # 0 = Maligno, 1 = Benigno
print(df.head())
```

y podemos dibujar la estimación de densidad de kernel (KDE) así:

```
import matplotlib.pyplot as plt
import seaborn as sns

var = 'mean radius'
plt.figure(figsize=(7, 5))
sns.kdeplot(data=df, x=var, hue='target', fill=True, common_norm=False)
plt.xlabel(var)
plt.tight_layout()
plt.show()
```

5.1 “Positivo” o “negativo” en contexto clínico

En problemas de clasificación médica, los términos **positivo** y **negativo** se refieren al resultado clínico esperado con respecto a la presencia o ausencia de una enfermedad:

- **Positivo clínico:** el modelo predice que la persona tiene la enfermedad.
- **Negativo clínico:** el modelo predice que la persona no tiene la enfermedad.

5.2 Matriz de confusión

La matriz de confusión es una tabla que nos permite evaluar el rendimiento de un modelo de clasificación comparando sus predicciones con los valores reales. En el caso de una clasificación binaria, la matriz tiene la siguiente estructura:

	Predicho: Maligno (0)	Predicho: Benigno (1)
Real: Maligno (0)	TP	FN
Real: Benigno (1)	FP	TN

donde:

- **TP (True Positive)** – Casos **malignos** correctamente clasificados como **malignos**.
- **FN (False Negative)** – Casos **malignos** incorrectamente clasificados como **benignos**.
- **FP (False Positive)** – Casos **benignos** incorrectamente clasificados como **malignos**.
- **TN (True Negative)** – Casos **benignos** correctamente clasificados como **benignos**.

Para visualizar la matriz de confusión (generada a mano), se usa:

```
import seaborn as sns
import matplotlib.pyplot as plt
cm = [[50, 10], [5, 35]]
plt.figure(figsize=(5, 4))
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues',
            xticklabels=['Maligno (0)', 'Benigno (1)'],
            yticklabels=['Maligno (0)', 'Benigno (1)'])
plt.xlabel('Predicción')
plt.ylabel('Valor Real')
plt.tight_layout()
plt.show()
```

5.3 Métricas de evaluación

A partir de la matriz de confusión, podemos calcular varias métricas importantes.

La **exactitud** (*accuracy*) mide la proporción de predicciones correctas sobre el total de muestras:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Esta métrica es útil cuando las clases están balanceadas, pero puede ser engañosa si hay un desbalance significativo.

La **precisión** (*precision*) nos indica qué tan confiable es el modelo cuando predice un caso como maligno:

$$\text{Precision} = \frac{TP}{TP + FP}$$

Si la precisión es alta, significa que hay pocos falsos positivos (FP), es decir, el modelo rara vez clasifica erróneamente un caso benigno como maligno.

La **sensibilidad** (*recall*), también llamada **tasa de verdaderos positivos** (TPR, *True Positive Rate*), responde a la pregunta: de todos los casos realmente malignos, ¿cuántos logré identificar correctamente?

$$\text{Recall} = \frac{TP}{TP + FN}$$

Si el recall es bajo, significa que hay muchos falsos negativos (FN), es decir, tumores malignos que fueron clasificados erróneamente como benignos.

Finalmente, el **F1-score** es la media armónica entre la precisión y el recall:

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Es útil cuando hay desbalance de clases, ya que ofrece una evaluación equilibrada del rendimiento del modelo sin favorecer ni la precisión ni el recall.

En un problema de clasificación de tumores, la elección de la métrica afecta directamente la evaluación médica:

- En contextos médicos, suele ser prioritario maximizar la **sensibilidad** (*recall*), lo que significa reducir la cantidad de **falsos negativos**. En un diagnóstico de cáncer, un tumor maligno no detectado puede poner en riesgo la vida del paciente al retrasar el tratamiento adecuado.
- Se puede complementar el modelo con pruebas adicionales. En la práctica clínica, es común ajustar el umbral de decisión para favorecer la sensibilidad y luego realizar estudios confirmatorios (biopsias, resonancias, etc.) para mejorar la precisión y reducir los falsos positivos.
- El **F1-score** puede ser una métrica útil, ya que equilibra precisión y sensibilidad. Sin embargo, cuando el costo de un falso negativo es elevado, se recomienda priorizar la sensibilidad, incluso a expensas de la precisión.

6 Tarea

Para evaluar qué tan bien sirven estas variables para predecir el diagnóstico, seguimos una estrategia de **valor de umbral**.

1. Selecciona arbitrariamente **tres** variables del conjunto que tengan distinta correlación con el diagnóstico:
 - (a) La primera variable debe tener una correlación cercana a cero.
 - (b) La segunda variable debe tener una correlación moderada, entre $|0.3|$ y $|0.5|$.
 - (c) La tercera variable debe tener una correlación alta, mayor que $|0.75|$.

Puedes utilizar `df.corr()['target']` para obtener la correlación de todas las variables con el diagnóstico (**target**), y luego ordenar los valores absolutos.

2. Estudia las **tres variables**, puedes usar `df['VARIABLE'].describe()` para analizar su distribución y valores estadísticos.
3. Dibuja las variables para tumores malignos y benignos, y usa la estimación de densidad de kernel (KDE) para visualizar su distribución. Escoge “a ojo” **un valor de umbral para cada variable** que te ayudará a clasificar los tumores como malignos o benignos.
4. El siguiente paso es evaluar qué tan bien podemos predecir si un tumor es maligno o benigno dado un valor de umbral. Para ello, asigna tus propias **etiquetas de clasificación**: esto significa que defines una nueva variable `df['prediction']`.

Veamos este ejemplo:




Figure 1: Mean radius

La figura 1 nos dice que un "mean radius" alto es relacionado con `target=0`, que es maligno. Supongamos que a ojo mi umbral es 15. Entonces la regla para crear `df['prediction']` en este caso es:

Si el valor de `mean radius` es **mayor o igual** al umbral, predice **maligno** (0). Si el valor es **menor**, predice **benigno** (1).

5. Crea tus propias etiquetas de clasificación e imprime las primeras 30 filas con los valores reales del diagnóstico y las predicciones generadas. ¿Por qué hay casos con `target = 0` (maligno) que tienen `prediction = 1` (benigno)?
6. Define FP (Falsos Positivos): casos donde el target real es 1 (benigno), pero la predicción es 0 (maligno). Cuéntalos y encuentra cuántas predicciones fallaron para cada una de las tres variables.
7. Calcula la matriz de confusión completa¹. Evalúa todas las 4 métricas que hemos visto manualmente. ¿Tu modelo con el corte en el umbral que escogiste es confiable?

¹Nota: la librería `sklearn` nos ofrece una función muy útil llamada `confusion_matrix()` que interpreta los valores de esta manera:

$$\text{confusion_matrix}(y_true, y_pred) \Rightarrow \begin{bmatrix} \text{TN} & \text{FP} \\ \text{FN} & \text{TP} \end{bmatrix}$$

Esta matriz asume que el valor 1 es el **positivo** y 0 es el **negativo**, lo cual es **al revés** del significado médico en este caso. Por eso, para evitar errores de interpretación, calcula los valores de TN, FP, FN y TP manualmente!