Temas Selectos de Física Computacional III: Introducción a la ciencia de datos. Clase 10: 09 de octubre de 2026

Dr. Jaime Octavio Guerra Pulido

1 Introducción

En esta clase, seguiremos estudiando los arboles de decisión (Decision Trees o DTs) utilizando `Scikit-learn`.

2 DTs para el conjunto de datos 2D sintético

1. Carga el conjunto de datos sintético "sintetico_2d.csv". Este conjunto tiene dos características y una etiqueta de clase. Utiliza la función `scatter()` de `matplotlib` para graficar el conjunto de datos en un plano 2D y colorea los puntos en función de su etiqueta de clase.

2. Construye un árbol de decisión simple utilizando el conjunto de datos completo y luego visualiza el modelo aprendido. Qué está aprendiendo el árbol y por qué?

3. Los árboles de decisión de `sklearn` almacenan, para cada división que realizan, la información sobre la característica que están usando para la división y el valor umbral usado en la comparación. Puedes encontrar esta información en `clf.tree_.feature` y `clf.tree_.threshold`.

   Con esta información, puedes tomar el código de `dibujar_divisiones.py` y graficar las fronteras de decisión (es decir, los umbrales de las características) aplicados por el árbol de decisión en el conjunto de datos. Idealmente, deberías tener un gráfico 2D con líneas verticales y horizontales que dividan el plano en subregiones (una para cada hoja del árbol).

4. Identifica una **nueva variable muy simple** que se podría construir de las variables de entrada que permitiría al árbol de decisión aprender muy rápido de este problema.

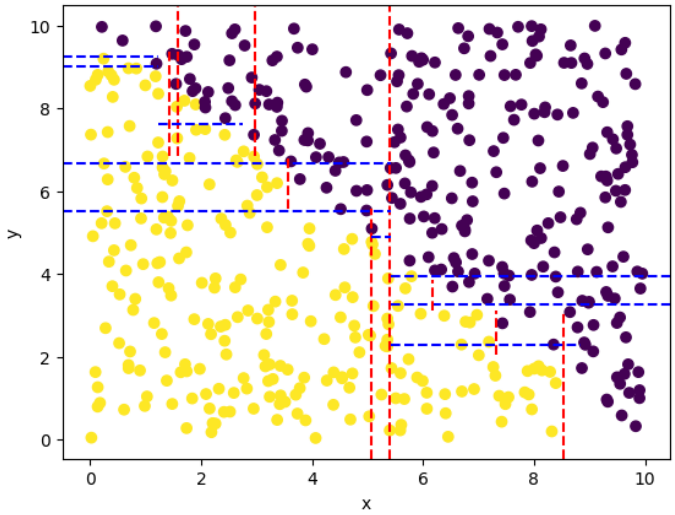


Figure 1: Subregiones para cada hoja de árbol de decisión.

3 DTs para el conjunto de lunas

1. Carga el conjunto de datos sintético de las lunas:

   ```
   from sklearn.datasets import make_moons
   X, y = make_moons(n_samples=1000, noise=0.1, random_state=123)
   ```

   Utiliza la función `scatter()` de `matplotlib` para graficar el conjunto de datos en un plano 2D y colorea los puntos en función de su etiqueta de clase.

2. Construye un árbol de decisión simple utilizando este conjunto de datos completo y visualizalo.

   ```
   from sklearn.tree import DecisionTreeClassifier
   moon_clf = DecisionTreeClassifier(random_state=123)
   ```

3. Ahora puedes tomar el código de `dibujar_frontera_decision.py` y graficar las fronteras de decisión

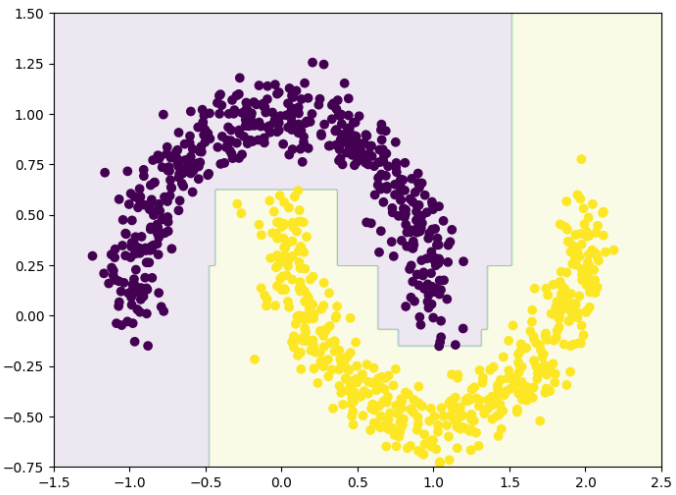


Figure 2: Fronteras de decisión.

4. Cambia la cantidad de ruido (por ejemplo `noise=0.5`) en las lunas.

5. Entrena un `DecisionTreeClassifier`, y compara la precisión en conjuntos de entrenamiento y prueba (80% entrenamiento, 20% test).

6. Demuestra que estamos en un claro caso de sobreajuste (overfitting). Compara `accuracy_score` de conjuntos de entrenamiento y prueba.